

**Chatbot para la Detección de Noticias Falsas mediante Procesamiento
del Lenguaje Natural y Arquitecturas Transformer**

Salinas Condori Ian Ezequiel C.I.: 13694034

Mamani Quisbert Ramiro Brandon C.I.: 9971522

Universidad mayor de San Andres

Facultad de Ciencias Puras y Naturales

Carrera de Informatica

Procesamiento del Lenguaje Natural (PLN)

Rosa Flores Morales

08 de Junio de 2026

Chatbot para la Detección de Noticias Falsas mediante Procesamiento del Lenguaje Natural y Arquitecturas Transformer

Introducción

La difusión de noticias falsas en redes sociales y aplicaciones de mensajería se ha convertido en un problema social de creciente relevancia. La velocidad con la que circula este tipo de contenido supera ampliamente la capacidad de las personas para verificarlo de manera manual, lo que facilita su aceptación acrítica y su propagación. Frente a este escenario, las herramientas automáticas de apoyo a la verificación adquieren un valor considerable.

En los últimos años, las técnicas de procesamiento del lenguaje natural (PLN) y, en particular, los modelos basados en arquitecturas Transformer han demostrado un desempeño sobresaliente en tareas de comprensión y clasificación de texto (Vaswani et al., 2017; Devlin et al., 2019). Estas capacidades permiten abordar la detección de desinformación como un problema de clasificación de lenguaje, aprovechando modelos preentrenados que capturan el contexto y el significado de las palabras.

El presente proyecto propone un chatbot en español que asiste al usuario evaluando si un texto noticioso presenta rasgos asociados a las noticias falsas, ofreciendo un veredicto acompañado de un nivel de confianza. Se concibe como una herramienta de apoyo a la decisión y no como un árbitro definitivo de la verdad. Para integrar la detección dentro de una experiencia conversacional, el sistema combina un núcleo de clasificación basado en Transformers con una capa de diálogo que reconoce las intenciones del usuario, extrae la información relevante y gestiona las respuestas.

Este informe documenta el desarrollo del proyecto desde su diseño hasta la evaluación del modelo de clasificación: se delimita el problema, se especifica la arquitectura conversacional y se detallan la preparación de los datos, el entrenamiento del modelo Transformer y su evaluación. La integración del clasificador en la interfaz conversacional final constituye la etapa siguiente del trabajo.

Objetivos

Objetivo general

Diseñar e implementar un chatbot basado en arquitecturas Transformer capaz de asistir a los usuarios en la detección de posibles noticias falsas en español, mediante técnicas de procesamiento del lenguaje natural.

Objetivos específicos

- Delimitar el alcance del asistente, definiendo con claridad qué tareas debe realizar y cuáles quedan explícitamente fuera de su función.
- Definir las intenciones y las entidades que el chatbot debe reconocer a partir de los mensajes del usuario.
- Diseñar el flujo conversacional, los guiones de diálogo y los mecanismos de manejo de excepciones (*fallbacks*).
- Seleccionar y preparar un conjunto de datos de noticias en español, ajustar (*fine-tuning*) un modelo Transformer para la clasificación y evaluar su desempeño.

Descripción del problema

Problema que resuelve

La aceptación y reenvío acrítico de noticias falsas genera efectos negativos en distintos ámbitos sociales. Dado que verificar cada noticia de forma manual resulta lento y poco práctico para el usuario común, el proyecto propone un chatbot que ofrece una evaluación automática y rápida sobre si un texto noticioso presenta características propias de la desinformación, funcionando como un primer filtro que apoya la decisión del usuario.

Tareas que debe cumplir

El asistente debe recibir un titular o el cuerpo de una noticia, clasificarlo como probablemente verdadero o probablemente falso acompañado de un nivel de confianza, señalar de manera

general en qué rasgos se apoya dicha clasificación y sostener una conversación básica que permita al usuario solicitar aclaraciones u orientación.

Tipo de usuario

El chatbot está orientado a un público general sin conocimientos técnicos: estudiantes, personas que reciben noticias a través de redes sociales o aplicaciones de mensajería y, eventualmente, comunicadores en una etapa preliminar de verificación. En consecuencia, se prioriza un lenguaje claro y accesible en todas las respuestas.

Restricciones del sistema

Con el fin de delimitar el alcance y evitar expectativas erróneas, se establece de manera explícita lo que el sistema no debe hacer:

- No constituye un verificador de hechos definitivo ni reemplaza el trabajo de un profesional; entrega una probabilidad, no una sentencia.
- No busca la noticia en internet ni la contrasta con fuentes en tiempo real: analiza únicamente el texto que recibe.
- No emite opiniones políticas ni evalúa posturas ideológicas.
- No procesa imágenes, audio ni video; trabaja exclusivamente con texto.
- No garantiza una exactitud del cien por ciento, y comunica de forma transparente cuando su nivel de confianza es bajo.
- No almacena ni comparte datos sensibles del usuario.

Descripción del chatbot

Intenciones

A partir del análisis de las interacciones esperadas, se definieron seis intenciones que el chatbot debe reconocer:

- **Saludar:** el usuario inicia la conversación (por ejemplo, “hola” o “buenos días”).

- **Verificar noticia:** intención principal del sistema; el usuario aporta un titular o un texto noticioso para su evaluación.
- **Explicar resultado:** el usuario solicita conocer las razones de una clasificación previa.
- **Solicitar ayuda:** el usuario consulta qué puede hacer el asistente o cómo funciona.
- **Despedirse:** el usuario finaliza la conversación.
- **Fuera de tema (*fallback*):** cualquier mensaje que no se ajuste a las intenciones anteriores.

En conformidad con los requisitos del proyecto, la identificación de estas intenciones no se fundamenta en reglas fijas basadas en palabras clave, sino en técnicas de PLN (por ejemplo, mediante la comparación de representaciones vectoriales de las frases o un clasificador de intenciones), lo que evita un comportamiento puramente basado en reglas.

Identificación de entidades

El sistema busca reconocer las siguientes entidades dentro de los mensajes del usuario:

- **Texto de la noticia:** el contenido que debe ser evaluado (entidad central).
- **Fuente o medio:** el origen de la noticia, cuando el usuario lo menciona.
- **Fecha:** el momento de publicación o de ocurrencia de los hechos.
- **Personas, organizaciones y lugares:** entidades nombradas presentes en el texto.

Para el reconocimiento de personas, organizaciones, lugares y fechas se prevé el uso del módulo de reconocimiento de entidades nombradas de la biblioteca spaCy para el idioma español (`es_core_news_nd`).

Flujo conversacional

El flujo conversacional, ilustrado en la Figura 1, inicia cuando el usuario envía un mensaje. El sistema clasifica la intención y, en función de ella, deriva el procesamiento hacia dos caminos. Cuando la intención es verificar una noticia, el mensaje pasa por la extracción del texto y de las

entidades, luego por el modelo Transformer que realiza la clasificación, y finalmente el sistema responde con el veredicto y su nivel de confianza. Cuando se trata de una intención conversacional (saludo, ayuda o despedida), el sistema genera una respuesta directa; si el mensaje no se comprende o queda fuera del alcance, se activa un mecanismo de desviación. Tras cada respuesta, el chatbot vuelve a quedar a la espera de un nuevo mensaje, lo que permitirá incorporar memoria conversacional para vincular una verificación con su posterior explicación.




Figura 1: Flujo conversacional del chatbot.

Guiones de diálogo

A continuación se presentan ejemplos representativos de interacción para las situaciones previstas.

Usuario: hola

Asistente: ¡Hola! Soy un asistente que te ayuda a detectar si una noticia podría ser falsa. Pégame el titular o el texto de una noticia y la analizo.

Usuario: «Científicos confirman que beber agua con limón cura el cáncer en tres días.»

Asistente: Analicé el texto y lo clasifico como probablemente falso (confianza del

92 %). Detecté un lenguaje sensacionalista y una afirmación médica extraordinaria sin fuente. ¿Quieres que te explique en qué me basé?

Usuario: sí, explícame

Asistente: La noticia utiliza expresiones típicas de la desinformación (cura milagrosa, plazos exagerados) y no cita estudios ni instituciones. Aun así, te recomiendo confirmarlo en fuentes oficiales de salud.

Usuario: ¿qué hora es?

Asistente: No manejo esa información. Lo que sí puedo hacer es ayudarte a verificar si una noticia parece falsa, ¿tienes alguna que quieras revisar?

Desviaciones (fallbacks)

Se previeron respuestas específicas para las situaciones en que el sistema no puede responder con normalidad:

- **Mensaje no comprendido:** el asistente aclara qué tareas puede realizar y solicita el texto de una noticia.
- **Texto demasiado corto:** solicita el titular o el cuerpo completo para poder evaluar con confianza.
- **Confianza baja del modelo:** comunica abiertamente su incertidumbre y recomienda verificar con fuentes oficiales, en lugar de simular certeza.
- **Tema fuera del alcance:** reencauza la conversación con amabilidad hacia su función principal.

Dataset utilizado

Para el entrenamiento y la evaluación del modelo se empleó el *Spanish Fake News Corpus* (Posadas-Durán et al., 2019), un conjunto de noticias en español etiquetadas como verdaderas o falsas que abarca diversas temáticas. El corpus se distribuye en dos particiones independientes

—entrenamiento y prueba— y cada registro consta de dos campos: el texto de la noticia y su clase (real o fake).

El conjunto de entrenamiento contiene 538 noticias y el de prueba 60, con la distribución por clase que se muestra en la Tabla 1. Un análisis exploratorio inicial confirmó que los datos no presentan valores nulos ni registros duplicados, por lo que no fue necesario descartar ejemplos. La distribución de clases evidencia un desbalance leve (una razón aproximada de 1.31 a 1 entre noticias reales y falsas), que no exige técnicas de aumento de datos y se aborda, en cambio, ponderando las clases durante el entrenamiento y reportando la métrica F1-macro.

Tabla 1: Distribución de clases en el conjunto de datos.

Partición	Reales	Falsas	Total
Entrenamiento	305	233	538
Prueba	34	26	60

En cuanto a la longitud de los textos, la noticia mediana ronda las 330 palabras y el percentil 95 alcanza las 767, con una marcada cola de textos extensos. Se observó, además, un sesgo de longitud: las noticias reales tienden a ser más largas que las falsas. Este hallazgo resultó determinante para fijar la longitud máxima de secuencia en la fase de tokenización y se tuvo presente al interpretar los resultados, a fin de descartar que el modelo discriminara apoyándose en la longitud. Finalmente, se verificó la viabilidad de extraer entidades nombradas (personas, lugares y organizaciones) mediante el módulo de reconocimiento de entidades de spaCy con el modelo `es_core_nevs_nd`, información que enriquecerá la capa conversacional del asistente.

Preprocesamiento del texto

A diferencia de los enfoques clásicos de PLN, las arquitecturas Transformer requieren un preprocesamiento mínimo. No se eliminan palabras vacías (*stopwords*) ni se aplica lematización o *stemming*, ya que el modelo es contextual y dispone de su propio tokenizador de subpalabras; suprimir esos elementos eliminaría el contexto que el modelo necesita. En consecuencia, el preprocesamiento se limitó a una limpieza ligera que elimina direcciones URL y normaliza los espacios

en blanco, conservando las mayúsculas y la puntuación, pues el modelo empleado distingue mayúsculas de minúsculas (*cased*) y las aprovecha como señal.

A continuación, las etiquetas se codificaron numéricamente, asignando el valor 0 a la clase real y el valor 1 a la clase fake; se tomó la clase falsa como positiva por ser el objetivo de detección del sistema. El conjunto de entrenamiento se dividió de forma estratificada en dos subconjuntos, destinando el 80 % al entrenamiento y el 20 % a la validación, y manteniendo intacta la partición de prueba para la evaluación final.

Por último, los textos se tokenizaron con el tokenizador de subpalabras del modelo preentrenado BETO. El análisis de la longitud en *tokens* reveló una mediana de 435 y un percentil 95 de 970, de modo que el 37.7 % de las noticias supera el límite de 512 *tokens* admitido por la arquitectura y resulta truncado. Se adoptó una longitud máxima de 512 *tokens* como compromiso estándar entre cobertura y costo computacional, asumiendo de manera explícita esta pérdida de información como una limitación del enfoque.


Arquitectura del modelo

El núcleo de clasificación se construyó sobre BETO (Cañete et al., 2020), un modelo BERT de tamaño base preentrenado específicamente con un gran corpus en español. BETO está compuesto por 12 capas Transformer, una dimensión oculta de 768 y aproximadamente 110 millones de parámetros. Dado que el modelo preentrenado solo produce representaciones contextuales de los textos, se le añadió una cabeza de clasificación: una capa lineal que, a partir del vector del token especial fCLS3 —de 768 dimensiones, que resume la secuencia completa—, genera dos valores (*logits*) correspondientes a las clases verdadera y falsa.

El procesamiento de cada noticia sigue un flujo bien definido. El texto se convierte, mediante el tokenizador, en una secuencia de identificadores (*input_ids*) acompañada de una máscara de atención (*attention_mask*) que distingue los *tokens* reales del relleno. BETO transforma esa secuencia en representaciones contextuales, de las que se toma el vector fCLS3 ; la cabeza lineal lo proyecta a dos *logits* y la función *softmax* los convierte en probabilidades, cuyo máximo determi-

na el veredicto y su nivel de confianza. Como función de pérdida se empleó la entropía cruzada, ponderada por la frecuencia inversa de cada clase para compensar el leve desbalance del conjunto. El desempeño se siguió mediante cuatro métricas: exactitud, F1-macro, precisión y exhaustividad (*recall*).

Arquitectura del Clasificador de Noticias Falsas basado en BETO



Entrenamiento

El ajuste fino se realizó durante tres épocas, con un tamaño de lote de 8, una tasa de aprendizaje de 2×10^{-5} , un decaimiento de pesos de 0.01 y una longitud máxima de 512 *tokens*. El proceso se ejecutó sobre CPU y requirió aproximadamente 54 minutos. Al finalizar cada época se evaluó el modelo sobre el conjunto de validación y se conservó automáticamente el punto de control con la mejor F1-macro. La Tabla 2 resume la evolución de las métricas.

Tabla 2: Evolución de las métricas durante el entrenamiento (conjunto de validación).

Época	Pérdida ent.	Pérdida val.	Exactitud	F1-macro	Precisión	Exhaustividad
1	0.308	0.168	0.935	0.935	0.933	0.938
2	0.070	0.335	0.944	0.942	0.955	0.936
3	0.004	0.296	0.944	0.943	0.950	0.939

Los resultados evidencian un comportamiento de sobreajuste: la pérdida sobre el conjunto de entrenamiento desciende hasta valores cercanos a cero, mientras que la de validación aumenta

tras la primera época. Este fenómeno es esperable dado el tamaño reducido del conjunto de entrenamiento (430 ejemplos). No obstante, las métricas de clasificación se mantienen estables, lo que se explica porque el modelo conserva sus aciertos aun cuando incrementa la confianza de sus predicciones. Para obtener un modelo mejor calibrado podrían reducirse las épocas de entrenamiento o intensificarse la regularización.

Resultados

Sobre el conjunto de validación, el modelo seleccionado (el de la tercera época) alcanzó una exactitud del 94.4 %, una F1-macro del 94.3 %, una precisión del 95.0 % y una exhaustividad del 93.9%. La evaluación definitiva se realizó sobre el conjunto de prueba, compuesto por 60

noticias que el modelo no había visto durante el entrenamiento: en él clasificó correctamente 59 de las 60 noticias, lo que equivale a una exactitud del 98.3 % con un único caso mal clasificado. El tiempo medio de inferencia, medido sobre GPU, fue de 49 milisegundos por noticia, una latencia adecuada para sostener una interacción conversacional fluida.

Evaluación

El desempeño en el conjunto de prueba (98.3 %) resultó incluso superior al obtenido en validación, lo que sugiere una buena capacidad de generalización del modelo. Conviene, no obstante, interpretar esta cifra con cautela: dado que el conjunto de prueba contiene solo 60 noticias, un acierto o error adicional modifica el porcentaje de forma apreciable, por lo que el resultado debe entenderse como muy favorable, mas no como una medida de exactitud absoluta.

El análisis de los errores aportó una observación relevante. El único caso mal clasificado correspondió a un texto extenso (870 palabras, frente a una media de 404 en los aciertos). Este resultado es coherente con la limitación de truncamiento identificada en la fase de preprocesamiento: al superar ampliamente los 512 *tokens*, el texto perdió más de la mitad de su contenido y, con ello, información potencialmente útil para la clasificación. Cabe destacar que el error no se asoció a textos cortos, lo que matiza el riesgo del sesgo de longitud señalado durante el análisis exploratorio. En conjunto, el modelo exhibe un desempeño elevado y un tiempo de respuesta apropiado, si bien sus principales limitaciones son el truncamiento de los textos más largos y el tamaño reducido del conjunto de datos.

Conclusiones

- Alto desempeño del modelo: En el conjunto de prueba, el modelo alcanzó una exactitud del 98.3%, clasificando de manera correcta 59 de las 60 noticias. Esto sugiere que el modelo tiene una buena capacidad de generalización. No obstante, el informe advierte que esta cifra debe interpretarse con cautela debido al tamaño reducido de dicho conjunto.
- Velocidad de respuesta: El tiempo de inferencia promedio fue de 49 milisegundos por noticia utilizando GPU. Se determinó que esta latencia es apropiada para poder sostener una interacción conversacional fluida en el chatbot.
- Análisis de errores y limitaciones: En conjunto, el modelo presenta un desempeño elevado, pero sus mayores limitaciones son el tamaño reducido del conjunto de datos y el truncamiento de los textos más largos. De hecho, la única falla de clasificación ocurrió en un texto extenso de 870 palabras, lo cual es coherente con la pérdida de información que sufre el texto al superar el límite de 512 tokens permitido por la arquitectura.

Referencias

- Cañete, J., Chaperon, G., Fuentes, R., Ho, J.-H., Kang, H., & Pérez, J. (2020). Spanish pre-trained BERT model and evaluation data. En *PML4DC at ICLR 2020*.
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. En *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics* (pp. 4171–4186).
- Honnibal, M., & Montani, I. (2017). *spaCy 2: Natural language understanding with Bloom embeddings, convolutional neural networks and incremental parsing*.
- Posadas-Durán, J. P., Gómez-Adorno, H., Sidorov, G., & Moreno-Escobar, J. J. (2019). Detection of fake news in a new corpus for the Spanish language. *Journal of Intelligent & Fuzzy Systems*, 36(5), 4869–4876.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. En *Advances in Neural Information Processing Systems* (Vol. 30).
- Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., . . . Rush, A. M. (2020). Transformers: State-of-the-art natural language processing. En *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations* (pp. 38–45).